

FUNDAÇÃO GETÚLIO VARGAS
ESCOLA DE ECONOMIA SÃO PAULO
MESTRADO PROFISSIONAL EM ECONOMIA E FINANÇAS

**APRENDIZADO DE MÁQUINA
PARA ANÁLISE DE CURVAS DE JUROS**

Luis Cláudio De Giovanni Pache de Faria

Orientador: Prof. Marcelo Fernandes

SEMINÁRIOS DE DISSERTAÇÃO II

OBJETIVO

Executar rotinas do modelo Kernel-Ridge não paramétrico de aprendizado de máquina para projeção de curvas de juros, proposta por Filipovitch, Pelger e Ye (2022), e compará-la aos modelos paramétricos correntemente usados, mais notavelmente o de Nelson, Siegel e Svensson (1994) dentro do contexto de títulos públicos brasileiros.

PERGUNTA

Como o modelo Kernel-Ridge se compara a modelos paramétricos para projeção de curva de juros de títulos públicos brasileiros sob o ponto de vista de usabilidade, precisão e robustez?

CONTRIBUIÇÃO

Aplicar localmente um modelo moderno de aprendizado de máquina para projeção de curva de juros dentro do ambiente de títulos públicos brasileiros e divulgar esta nova metodologia no nosso meio acadêmico.

REVISÃO DA LITERATURA – DE POOTER (2007)

Definições preliminares

- Taxa de juros futura instantânea
- Taxa de juros a termo
- Curva de desconto
- Relação biunívoca

$$\lim_{\tau^* \downarrow 0} f_t(\tau, \tau^*) = f_t(\tau)$$

$$y_t(\tau) = \frac{1}{\tau} \int_0^\tau f_t(m) dm$$

$$P_t(\tau) = \exp[-\tau y_t(\tau)]$$

$$f_t(\tau) = -\frac{1}{P_t(\tau)} \frac{dP_t(\tau)}{d\tau} = y_t(\tau) + \tau \frac{dy_t(\tau)}{d\tau}$$

Modelos Paramétricos

- Nelson e Siegel (1987)
- Svensson (1994)

$$y_t(\tau) = \beta_{1,t} + \beta_{2,t} \left[\frac{1 - \exp\left(-\frac{\tau}{\lambda_t}\right)}{\left(\frac{\tau}{\lambda_t}\right)} \right] + \beta_{3,t} \left[\frac{1 - \exp\left(-\frac{\tau}{\lambda_t}\right)}{\left(\frac{\tau}{\lambda_t}\right)} - \exp\left(-\frac{\tau}{\lambda_t}\right) \right]$$

$$y_t(\tau) = \beta_{1,t} + \beta_{2,t} \left[\frac{1 - \exp\left(-\frac{\tau}{\lambda_{1,t}}\right)}{\left(\frac{\tau}{\lambda_{1,t}}\right)} \right] + \beta_{3,t} \left[\frac{1 - \exp\left(-\frac{\tau}{\lambda_{1,t}}\right)}{\left(\frac{\tau}{\lambda_{1,t}}\right)} - \exp\left(-\frac{\tau}{\lambda_{1,t}}\right) \right] + \beta_{4,t} \left[\frac{1 - \exp\left(-\frac{\tau}{\lambda_{2,t}}\right)}{\left(\frac{\tau}{\lambda_{2,t}}\right)} - \exp\left(-\frac{\tau}{\lambda_{2,t}}\right) \right]$$

Modelos não Paramétricos

- Liu e Wu (2021)

$$\hat{g}_{LW}(x) = \frac{\sum_{n=1}^{360} K_{h(x)}(n-x) \exp(-(y_n + (x-n)y'_n)x)}{\sum_{n=1}^{360} K_{h(x)}(n-x)}$$

$$K_{h(x)}(n-x) = \frac{1}{\sqrt{2\pi h(x)^2}} \exp\left(-\frac{(n-x)^2}{2h(x)^2}\right)$$

- Filipovic, Pelger e Ye (2022): apresentado adiante

REVISÃO DA LITERATURA – THEODORIDIS (2015)

Regressão Ridge - Penalizar função de perda quadrática

$$\hat{\theta}_{LS} = \arg \min_{\theta} \sum_{n=1}^N (y_n - \theta^T x_n)^2. \quad \longrightarrow \quad \begin{array}{ll} \text{minimize:} & J(\theta) = \sum_{n=1}^N (y_n - \theta^T x_n)^2, \\ \text{subject to:} & \|\theta\|^2 \leq \rho, \end{array}$$

$$\text{minimize:} \quad L(\theta, \lambda) = \sum_{n=1}^N (y_n - \theta^T x_n)^2 + \lambda \|\theta\|^2 : \text{ Ridge Regression.} \quad \longrightarrow \quad \hat{\theta}_R = \arg \min_{\theta} \left\{ \|y - X\theta\|^2 + \lambda \|\theta\|^2 \right\}$$

Reproducing kernel Hilbert Spaces (RKHS)

Consideremos um espaço linear \mathbb{H} de funções de valores reais definidas em um conjunto $\mathcal{X} \subseteq \mathbb{R}^1$ tal que \mathbb{H} seja um espaço Hilbert, ou seja, que exista um operador de produto interno $\langle \cdot, \cdot \rangle_{\mathbb{H}}$ que defina a norma correspondente $\|\cdot\|_{\mathbb{H}}$, e que \mathbb{H} seja completo em relação a esta norma. Um espaço Hilbert \mathbb{H} é chamado de *reproducing kernel Hilbert space* (RKHS) se existe uma função $\kappa: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ tal que para cada $x \in \mathcal{X}$, $\kappa(\cdot, x)$ pertence a \mathbb{H} , e além disso $\kappa(\cdot, \cdot)$ possui a chamada *reproducing property*:

$$f(x) = \langle f, \kappa(\cdot, x) \rangle, \quad \forall f \in \mathbb{H}, \quad \forall x \in \mathcal{X} : \quad \text{Reproducing Property.}$$

$$\mathcal{X} \ni x \longmapsto \phi(x) := \kappa(\cdot, x) \in \mathbb{H} : \quad \text{Feature Map,} \quad \longrightarrow \quad \langle \phi(x), \phi(y) \rangle = \kappa(x, y) : \quad \text{Kernel Trick.}$$

Regressão Kernel Ridge

Regressão não linear: $y_n = g(x_n) + \eta_n, \quad n = 1, 2, \dots, N.$

Teorema da representação: f estimador de g em RKHS

$$f(x) = \sum_{n=1}^N \theta_n \kappa(x, x_n).$$

$$\hat{\theta} = \arg \min_{\theta} J(\theta),$$

$$J(\theta) := \sum_{n=1}^N \left(y_n - \sum_{m=1}^N \theta_m \kappa(x_n, x_m) \right)^2 + C \langle f, f \rangle, \quad \longrightarrow \quad \hat{y} = \sum_{n=1}^N \hat{\theta}_n \kappa(x, x_n) = \hat{\theta}^T \kappa(x), \quad \longrightarrow \quad \hat{y}(x) = \mathbf{y}^T (\mathcal{K} + CI)^{-1} \kappa(x).$$

REVISÃO DA LITERATURA – FILIPOVIC, PELGER, YE (2022)

Problema Fundamental

Preços de títulos, sendo C = fluxos de caixa com dimensão $M \times N$ (M datas e N títulos)

$$P_i^g = \sum_{j=1}^N C_{ij} g(x_j). \quad \longrightarrow \quad P_i = P_i^g + \epsilon_i.$$

Otimização $\min_g \left\{ \sum_{i=1}^M \omega_i (P_i - P_i^g)^2 \right\}$ restrição (suavidade = sem arbitragem)

$$\|g\|_{\alpha, \delta} = \left(\int_0^\infty (\delta g'(x)^2 + (1 - \delta) g''(x)^2) e^{\alpha x} dx \right)^{\frac{1}{2}}$$



$$\min_{g \in \mathcal{G}_{\alpha, \delta}} \left\{ \underbrace{\sum_{i=1}^M \omega_i (P_i - P_i^g)^2}_{\text{pricing error}} + \lambda \underbrace{\|g\|_{\alpha, \delta}^2}_{\text{smoothness}} \right\}$$

com pesos

$$\omega_i = \frac{1}{M} \frac{1}{(D_i P_i)^2}$$

Solução Geral

$$\hat{g}(x) = 1 + \sum_{j=1}^N k(x, x_j) \beta_j, \quad \text{com} \quad \beta = C^\top (CKC^\top + \Lambda)^{-1} (P - C1), \quad \text{matriz kernel } \mathcal{K}_{ij} = k(x_i, x_j) \quad N \times N, \quad \Lambda = \text{diag}(\lambda/\omega_1, \dots, \lambda/\omega_M)$$

$$\alpha = 0, \delta \in (0, 1): \quad k(x, y) = \frac{1}{\delta} (x \wedge y) + \frac{1}{2\delta\rho} \left(e^{-\rho(x+y)} - e^{\rho(x \wedge y) - \rho(x \vee y)} \right) \quad \rho = \sqrt{\delta/(1-\delta)}$$

$$\alpha = 0, \delta = 1: \quad k(x, y) = x \wedge y$$

$$\alpha > 0, \delta = 1: \quad k(x, y) = -\frac{\alpha}{\delta \ell_2^2} \left(1 - e^{-\ell_2 x} - e^{-\ell_2 y} \right) + \frac{1}{\alpha \delta} \left(1 - e^{-\alpha(x \wedge y)} \right) + \frac{1}{\delta \sqrt{D}} \left(\frac{\ell_1^2}{\ell_2^2} e^{-\ell_2(x+y)} - e^{-\ell_1(x \wedge y) - \ell_2(x \vee y)} \right)$$

$$\alpha > 0, \delta = 1: \quad k(x, y) = \frac{1}{\alpha} \left(1 - e^{-\alpha(x \wedge y)} \right)$$

$$D = \alpha^2 + 4\delta/(1-\delta), \quad \ell_1 = \frac{\alpha - \sqrt{D}}{2}, \quad \text{and} \quad \ell_2 = \frac{\alpha + \sqrt{D}}{2}$$

$(\alpha, \delta) = (0, 0)$ não é especificado

(*) Notação $a \wedge b = \min\{a, b\}$ / $a \vee b = \max\{a, b\}$

BASE DE DADOS

Histórico de Preços e Taxas dos Títulos Públicos Federais

- <https://www.tesourodireto.com.br/titulos/historico-de-precos-e-taxas.htm>
- <http://www.tesourotransparente.gov.br/ckan/dataset/taxas-dos-titulos-ofertados-pelo-tesouro-direto>
- Tesouro prefixado LTN – 2002 a 2022 (21 arquivos)
- Tesouro prefixado com juros semestrais NFN-F – 2004 a 2022 (19 arquivos)
- Dados usados: Data base, Tipo de título, Vencimento, Preço PU

Data Frame

- 42.292 registros
- 4.681 datas base (janeiro de 2004 a novembro de 2022) em 213 meses
- 59 títulos (tipo e vencimento)
- *Sampling* – Datas base no último dia útil de cada mês (213 datas)

Filtros de outliers sugeridos pela literatura - Gürkaynak, Sack e Wright (2007) e Filipovic, Pelger e Ye (2022)

- Títulos com vencimento inferior a 90 dias
- Curva NSS - Erros acima de 3 desvios padrão das taxas baseado na seção cruzada temporal
- Curva KR - Erros acima de 3 desvios padrão das taxas baseado na seção cruzada temporal
- Estimação dos modelos com e sem filtros (Modelo KR robusto a outliers)

Simulação (resampling) – Filipovic, Pelger e Ye (2022)

- Suposição de taxas no próximo dia útil $t+1$ (teste) são virtualmente iguais às aquelas em t (treinamento)

METODOLOGIA

1. Compilação dos dados históricos de preços de títulos soberanos brasileiros pré-fixados;
2. Construção de rotinas em R e Python para tratamento dos dados de preços históricos;
3. Execução de otimização da função paramétricas Nelson-Siegel-Svensson em R através do método por algoritmo genético (aka *Differential Evolution*). Considerado também o método do Gradiente (aka *Steepest Descent*);
4. Execução de aprendizado de máquina com rotinas em Python para o modelo Kernel-Ridge com os hiper-parâmetros λ , α e δ fixos;
5. Tratamento e análise de resultados com rotinas em R considerando erros médios quadráticos (RMSE) ponderados pela duração, além de medidas de tensão e suavidade dos modelos NSS e KR, através de discretização numérica:

$$\text{RMSE} \quad \text{RMSE} = \frac{1}{T} \sum_{t=1}^T \text{RMSE}_t, \quad \text{RMSE}_t = \sqrt{\sum_{i=1}^{M_t} \omega_{i,t} (P_{i,t} - \hat{P}_{i,t}^g)^2}, \quad \text{com} \quad \omega_i = \frac{1}{M} \frac{1}{(D_i P_i)^2}$$

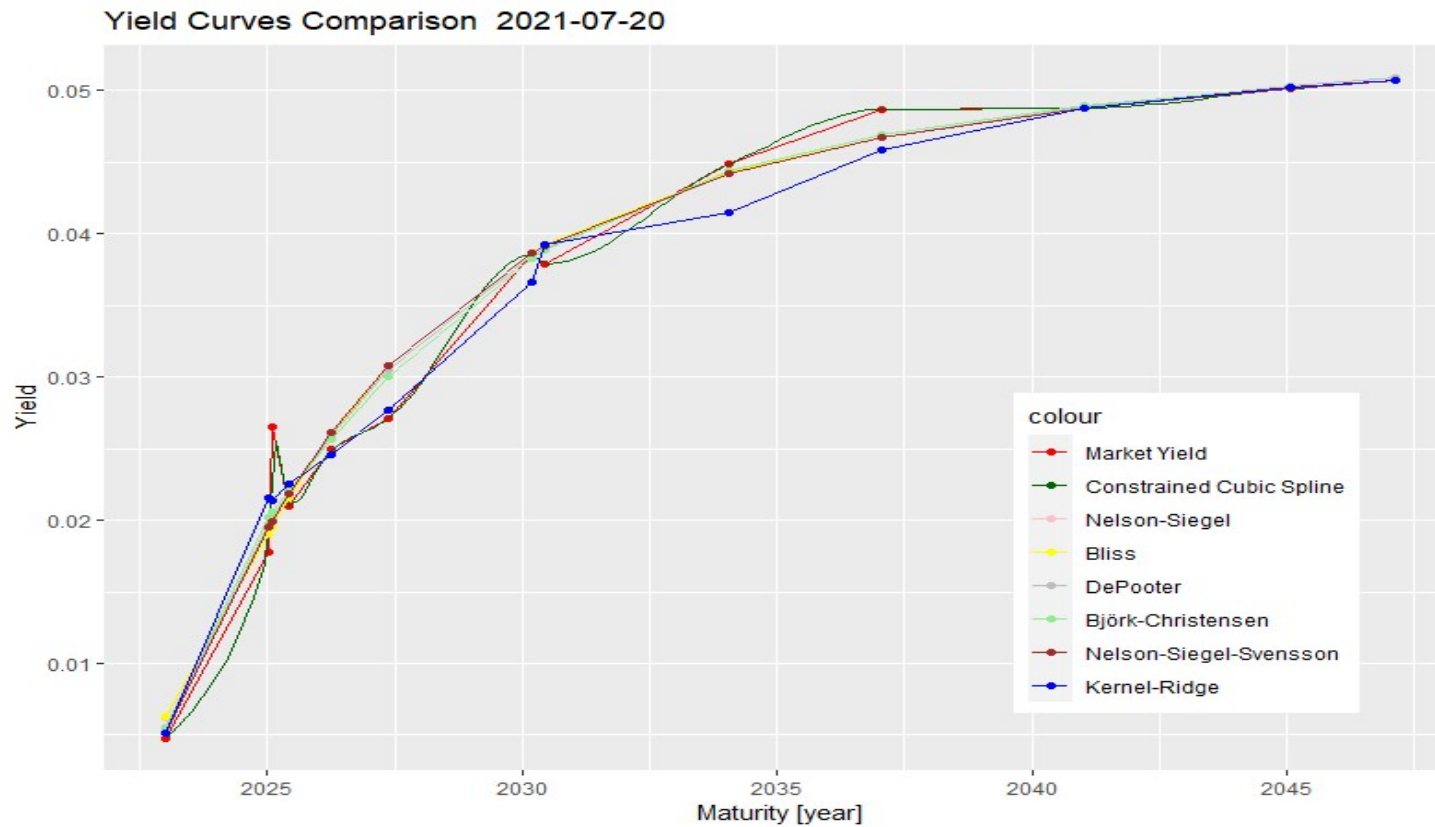
$$\text{Tensão e Suavidade:} \quad \frac{1}{|\mathcal{R}|} \int_{\mathcal{R}} g'(x)^2 dx \quad \text{e} \quad \frac{1}{|\mathcal{R}|} \int_{\mathcal{R}} g''(x)^2 dx$$

6. Confronto de cada modelo (NSS vs KR) com apresentação de conclusões, virtudes e limitações do modelo KR à luz de nossa realidade.


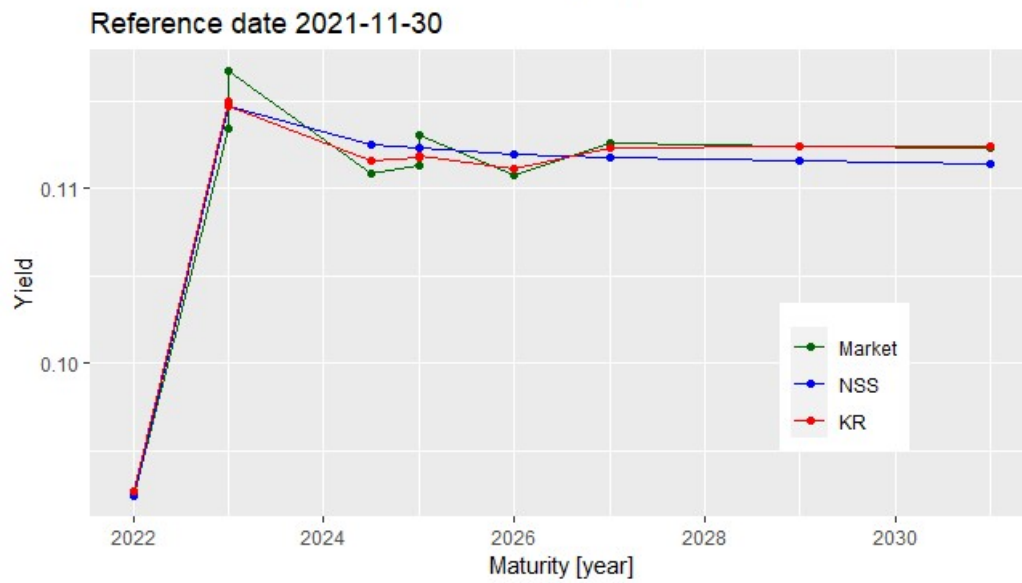
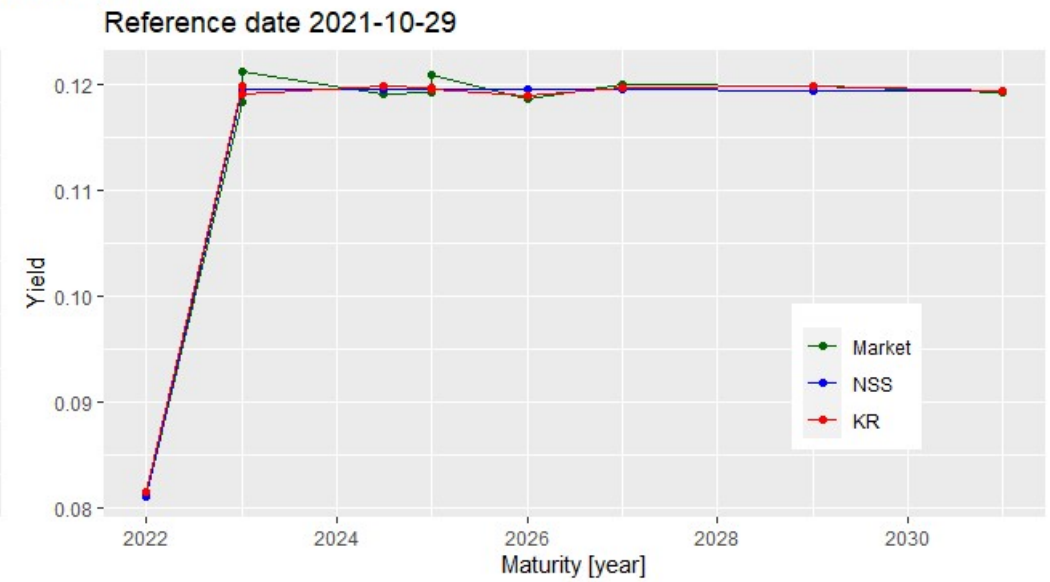

RESULTADOS PRELIMINARES

MODELOS ANALISADOS

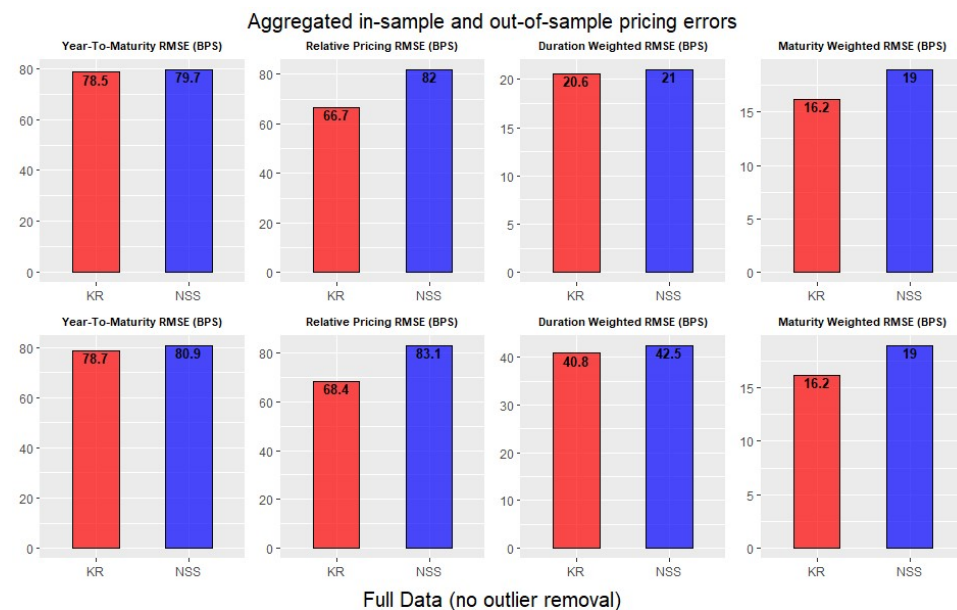
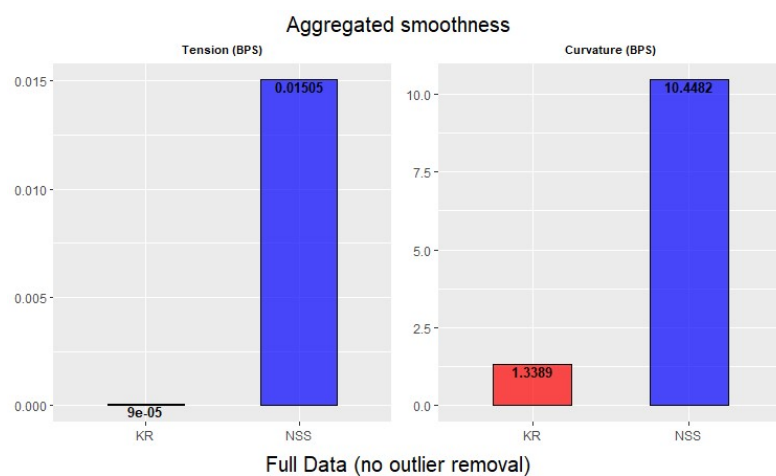

- Interpolação por Constrained Cubic Spline
- Paramétricos: Nelson-Siegel, Bliss, DePooter, Bjork-Christensen, Nelson-Siegel-Svensson (otimização por Algoritmos Genéticos)
- Não Paramétricos: Filipovic-Pelger-Ye (otimização por aprendizado de máquina Kernel-Ridge)



Multiple Dates Comparison

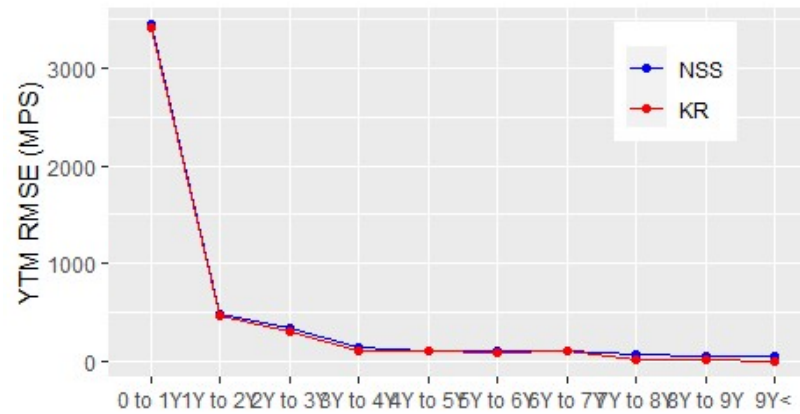


Full Data (no outlier removal)




Out-of-sample pricing errors for different maturities


Yield RMSE



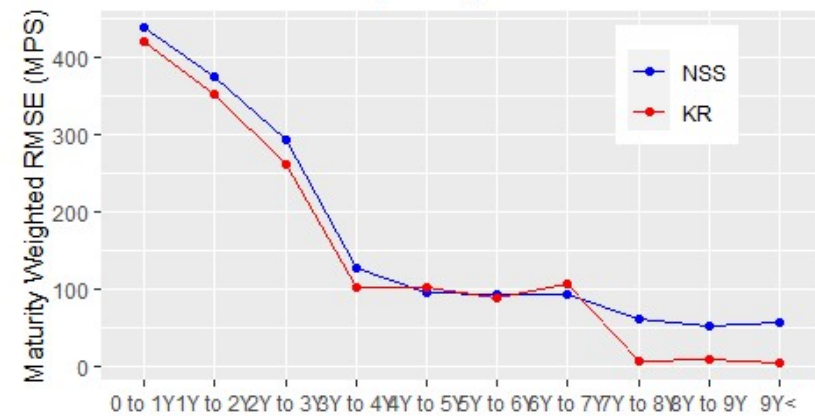
Relative Pricing RMSE



Duration Weighted RMSE



Maturity Weighted RMSE



Full Data (no outlier removal)